

ME315 Laboratório 2 - Processamento de Bases de Dados em Lote

Jhuan Marcos Nunes Solis Silva (266349)

Pacotes utilizados

```
library(readr)
library(dplyr)
library(tidyr)
library(ggplot2)
library(ggcal)
```

1. Estatísticas suficientes

Queremos, para cada combinação de **dia**, **mês** e **Cia. Aérea**, o percentual de vôos com `ARRIVAL_DELAY > 10`. Isso é uma proporção, logo as estatísticas suficientes são apenas duas (por grupo):

- `n`: número total de vôos do grupo;
- `n_atraso`: número de vôos do grupo com `ARRIVAL_DELAY > 10`.

O percentual final é obtido combinando os lotes por soma simples: `Perc = sum(n_atraso) / sum(n)`.

2. Função `getStats`

```
getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(ARRIVAL_DELAY), !is.na(DAY), !is.na(MONTH)) %>%
    group_by(DAY, MONTH, AIRLINE) %>%
```

```

    summarise(n_atraso = sum(ARRIVAL_DELAY > 10),
              n        = n(),
              .groups  = "drop")
}

```

3. Importação em lote com read_csv_chunked

Lemos apenas as colunas necessárias (MONTH, DAY, AIRLINE, ARRIVAL_DELAY) via `col_types`, com lotes de 100 mil linhas.

```

mycols <- cols_only(
  MONTH      = "i",
  DAY        = "i",
  AIRLINE    = "c",
  ARRIVAL_DELAY = "i"
)

stats_lotes <- read_csv_chunked(
  "flights.csv",
  callback    = DataFrameCallback$new(getStats),
  chunk_size  = 1e5,
  col_types   = mycols
)

```

```
stats_lotes
```

```

# A tibble: 1,478 x 5
   DAY MONTH AIRLINE n_atraso    n
  <int> <int> <chr>      <int> <int>
1     1     1     1 AA         514 1379
2     1     1     1 DL         132 1558
3     1     1     1 UA         367 1269
4     1     1     1 US         201 1028
5     2     2     1 AA         649 1508
6     2     2     1 DL         406 2261
7     2     2     1 UA         493 1411
8     2     2     1 US         229 1174
9     3     3     1 AA         767 1425
10    3     3     1 DL         702 2021
# i 1,468 more rows

```

4. Função computeStats

```
computeStats <- function(stats) {  
  stats %>%  
    group_by(Cia = AIRLINE, MONTH, DAY) %>%  
    summarise(n_atraso = sum(n_atraso),  
              n        = sum(n),  
              .groups  = "drop") %>%  
    mutate(Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),  
           Perc = n_atraso / n) %>%  
    select(Cia, Data, Perc)  
}
```

```
resultado <- stats_lotes %>% computeStats()  
resultado
```

```
# A tibble: 1,276 x 3  
  Cia    Data      Perc  
  <chr> <date>    <dbl>  
1 AA    2015-01-01 0.373  
2 AA    2015-01-02 0.430  
3 AA    2015-01-03 0.538  
4 AA    2015-01-04 0.602  
5 AA    2015-01-05 0.491  
6 AA    2015-01-06 0.366  
7 AA    2015-01-07 0.355  
8 AA    2015-01-08 0.307  
9 AA    2015-01-09 0.342  
10 AA   2015-01-10 0.280  
# i 1,266 more rows
```

5. Mapa de calor em formato de calendário


```
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")
```

```
baseCalendario <- function(stats, cia) {  
  sub <- stats %>% filter(Cia == cia)  
  ggcal(sub$Data, sub$Perc)  
}
```

```
cAA <- baseCalendario(resultado, "AA")
cDL <- baseCalendario(resultado, "DL")
cUA <- baseCalendario(resultado, "UA")
cUS <- baseCalendario(resultado, "US")
```


```
cAA + pal + ggtitle("Percentual de atraso na chegada - American Airlines")
```

Percentual de atraso na chegada – American Airlines




```
cDL + pal + ggtitle("Percentual de atraso na chegada - Delta Air Lines")
```

Percentual de atraso na chegada – Delta Air Lines




```
cUA + pal + ggtitle("Percentual de atraso na chegada - United Airlines")
```

Percentual de atraso na chegada – United Airlines



```
cUS + pal + ggtitle("Percentual de atraso na chegada - US Airways")
```

Percentual de atraso na chegada – US Airways



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 19:55:18 -03"
```