Laboratório 2: Dados Relacionais com Polars

Jhuan Marcos Nunes Solis Silva - 266349

```
# Disponibiliza o Polars no ambiente Python
reticulate::py_require("polars")
```

Carregamento dos dados

```
import polars as pl

# Lê os arquivos da pasta do projeto
basics = pl.scan_csv(
    "title.basics0.tsv", separator="\t", null_values=r"\N", quote_char=None
)
ratings = pl.scan_csv(
    "title.ratings.tsv", separator="\t", null_values=r"\N", quote_char=None
)
principals = pl.scan_csv(
    "title.principals0.tsv", separator="\t", null_values=r"\N", quote_char=None
)

# Relaciona filmes e avaliações
filmes_avaliados = (
    basics
    .filter(pl.col("titleType") == "movie")
    .select("tconst", "primaryTitle", "genres")
    .join(ratings.select("tconst", "averageRating", "numVotes"), on="tconst")
)
```

Atividade 1 — Cinco filmes com maiores notas

Em caso de empate na nota, prevalece o maior número de votos.

```
top5 = (
    filmes_avaliados
    .select("primaryTitle", "averageRating", "numVotes")
    .sort(["averageRating", "numVotes"], descending=[True, True])
    .head(5)
    .collect()
)
print(top5)
```

```
shape: (5, 3)

 primaryTitle               averageRating   numVotes
 ---                        ---             ---
 str                        f64             i64

 Kaveri                     10.0            1023
 Kurukku                    10.0            451
 Jedal Dar Omghe 30 Metri   10.0            142
 Sargashte                  10.0            134
 Gorgeous Rascal            10.0            115
```

Atividade 2 — Gênero mais frequente entre filmes com nota maior que 8

```
genero_mais_frequente = (
    filmes_avaliados
    .filter(pl.col("averageRating") > 8)
    .select(pl.col("genres").str.split(",").explode().alias("genero"))
    .filter(pl.col("genero").is_not_null())
    .group_by("genero")
    .agg(pl.len().alias("frequencia"))
    .sort("frequencia", descending=True)
    .head(1)
    .collect()
)
print(genero_mais_frequente)
```

```
shape: (1, 2)
```

```
 genero       frequencia
 ---          ---
 str          u32

 Documentary  10564
```

Atividade 3 — Três atores/atrizes com mais filmes de nota maior que 7,5

```
top3_atores = (
    principals
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .join(
        filmes_avaliados
        .filter(pl.col("averageRating") > 7.5)
        .select("tconst"),
        on="tconst"
    )
    .group_by("nconst")
    .agg(pl.col("tconst").n_unique().alias("participacoes"))
    .sort(["participacoes", "nconst"], descending=[True, False])
    .head(3)
    .collect()
)
print(top3_atores)
```

```
shape: (3, 2)

 nconst     participacoes
 ---        ---
 str        u32

 nm0004660  199
 nm0595934  155
 nm3183374  124
```

Data e hora da execução

```
print(format(Sys.time(), "%d/%m/%Y %H:%M:%S %Z", tz = "America/Sao_Paulo"))
```

```
[1] "14/10/2026 17:08:49 -03"
```